



时频图 (Spectrogram)



power_时频图



itc_时频图

三种不同的时序估计方法：[Multitaper](#)、[Morlet](#)、[Stockwell](#)。

人工智能技术在睡眠医学领域的应用与展望

睡眠分期

- 1. 基于传统机器学习的睡眠分期方法。
基于传统机器学习的睡眠分期方法通常分为两步，第一步是信号的预处理、特征的提取与选择，第二步为分类器的选择和应用。

| 标题 | 作者 | 特征提取方法 | 信号 | 结果 | 分类器 |
|----|----|--------|----|----|-----|
|----|----|--------|----|----|-----|

| 标题 | 作者 | 特征提取方法 | 信号 | 结果 | 分类器 |
|--|---------------------------|--|---------------------------|---|------|
| A decision support system for automatic sleep staging from EEG signals using tunable Q-factor wavelet transform and spectral features | Hassan A R, Bhuiyan M I H | tunable-Q factor wavelet transform (TQWT) | EEG | 90.38%, 91.50%, 92.11%, 94.80%, 97.50% | 随机森林 |
| Automatic sleep staging based on SVD, VMD, HHT and morphological features of single-lead ECG signal | Yucelbas S et al | Singular Value Decompo- sition (SVD), Variational Mode Decomposition (VMD), Hilbert Huang Transform (HHT), and Morphological | ECG(W、NREM、REM) | acc, Kappa coefficient and mean F-measure: 87.11%, 0.7369, 0.86 | 随机森林 |
| A decision support system for automatic sleep staging from HRV using wavelet packet decomposition and energy features | Geng D ,et al | : Hilbert HuangTransform (HHT), Singular Value Decomposition (SVD), and Wavelet Packet Decomposition (WPD) | HRV signal(wake、REM、NREM) | WPD: 80.9%, 88.2% and 65.8% | 随机森林 |

| 标题 | 作者 | 特征提取方法 | 信号 | 结果 | 分类器 |
|--|------------------------|--|-----------|--|-----|
| Ensemble SVM Method for Automatic Sleep Stage Classification | Emina Alickovic ,et al | discrete wavelet transform (DWT) | 单通道EEG | sensitivity: 84.46%, acc:91.1% | SVM |
| Comparative analysis of different characteristics of automatic sleep stages | Dechun Zhao,et al | kurtosis, skewness, Hjorth parameters, and standard deviations, wavelets energy; sample entropy (SampEn), fuzzy entropy, Tsallis entropy, fractal dimension (FD), complexity | 单通道EEG | The highest accuracy: 85.93% | SVM |
| Sleep staging algorithm based on multichannel data adding and multifeature screening | Wu Huang, et al | ReliefF algorithm | 两通道的EEG信号 | 98.28%, 95.50%, 94.28%, 93.08%, 92.34% | SVM |

| 标题 | 作者 | 特征提取方法 | 信号 | 结果 | 分类器 |
|---|----------------------|--------------------------------|--------------------------|--|-------------------------------------|
| A transition-constrained discrete hidden Markov model for automatic sleep staging | Shing-Tai Pan, et al | temporal and spectrum analyses | EEG, EOG and EMG signals | S1:85.29%, SWS:94.9%, S1:<34%). S1 was classified as Wake (21%), S2 (33%) or REM sleep (12%) | Discrete Hidden Markov Model (DHMM) |
| | | | | | |

2. 基于深度学习的睡眠分期方法
- 主要通过CNN、DBN 等实现特征的自动提取；通过长短期记忆网络（long short-term memory, LSTM）、双向门限循环神经网络（bidirectional gated recurrent unit, BiGRU）等学习特征中所蕴含的睡眠阶段间的序列关系；然后通过残差连接实现不同类型特征的融合；最后通过全连接的Softmax层对融合后的特征进行分类。
- 优点：深度学习方法可以通过不同的滤波器组提取不同的形态特征，如细节、结构和形状特征等。此外，深度学习方法可以从连续睡眠时期中提取时间序列信息来帮助分类。
3. 迁移学习
- 将大的数据集上训练出的模型参数迁移到小数据集的模型上，仅改变分类器的参数，通过微调等算法，仅需很少的训练迭代轮次即可获得不错的结果。

识别睡眠微事件

- 微事件：纺锤波、K复合波等
- 识别算法：SVM、贝叶斯、CNN+RNN等
- 意义：特征性波形（也称为睡眠微事件）是判别睡眠阶段的主要依据，同时也与睡眠质量、睡眠疾病等息息相关。
- 缺陷：当前的工作只做到了单一类别微事件的识别，并没有实现微事件的精准定位。然而，睡眠微事件的出现时刻、出现频率、持续长短与睡眠阶段、质量、病理、疾病等息息相关，可为临床睡眠疾病诊断、睡眠机制研究提供丰富的信息。

睡眠呼吸暂停中的应用

1. 基于传统机器学习的睡眠呼吸暂停识别方法

- 从心电中提取 R-R 间期序列或心率变异性 (heart rate variability, HRV), 或者是从 ECG 中提取出呼吸信号。最后送入分类器分类。
 - 结合具有可调 Q 因子的小波变换 (tunable-Q factor wavelet transform, TQWT) 和 RUSBoost (random under sampling boosting), 用来自动识别阻塞型睡眠呼吸暂停 (obstructive sleep apnea, OSA)
 - 结合 EEG、ECG 和血氧饱和度以获取丰富的生理信息, 运用机器学习的方法来检测睡眠呼吸暂停事件。
 - 利用呼吸暂停低通气指数 (apnea-hypopnea index, AHI) 来判断病症的严重程度
2. 基于深度学习的睡眠呼吸暂停识别方法
呼吸信号识别呼吸暂停事件, 考虑了从胸腹部呼吸运动或 ECG 中获得的呼吸信号。常用的分类器有 LSTM 等。
 3. 融合深度学习和机器学习的睡眠呼吸暂停识别方法
用深度学习来自动提取特征, 然后机器学习算法作为分类器来分类。

快动眼睡眠行为障碍中的应用

快动眼睡眠行为障碍 (REM sleep behavior disorder, RBD) 是一种异态睡眠, 特征是快速眼动睡眠期 (rapid eye movement, REM) 肌肉张力活动增多甚至伴发暴力活动及梦境回放。这方面的研究比较少, 有关文献的做法是: 对肌电和 ECG 进行预处理和滤波后, 使用滑动平均滤波器提取曲线的包络, 然后识别 ECG 中的 QRS 复合波, 同时识别 EMG 中的肌肉活动来检测 RSWA。

在失眠中的应用

这类研究相对于前两种数量要少得多, 主要的做法是利用 EEG 信号做一个健康和失眠的二分类识别。

在发作性睡病中的应用

发作性睡病是一种罕见的慢性睡眠障碍, 以 REM 睡眠异常为特征, 表现为睡眠-清醒失调 (白天嗜睡、猝倒、入睡幻觉、睡眠瘫痪和睡眠不安稳) 以及运动、认知、精神、代谢和自主神经功能紊乱。发作性睡病可以分为发作性睡病 1 型和发作性睡病 2 型。通常的做法是: 先利用 PSG 数据实现自动睡眠分期, 在分期结果的基础之上用于 I 型或 II 型的识别。